

Tina Face:

Tina Face temel object detection uygulamalarında kullanılan yöntemlerin face detection uygulamalarında da kullanılabileceği ve bu uygulamalarda güçlü fakat basit çözümler olacağını savunarak oluşturulan bir face detection yöntemidir.

FPN Nedir?

Birden fazla ölçekteki görüntülerin doğru ve hızlı bir şekilde işlenmesi için doğruluk ve hız göz önünde bulundurularak hazırlanmış bir özellik çıkarıcıdır.

Object detection için normal özellik piramidinden daha kaliteli bilgilerle birden fazla özellik haritası katmanı oluşturur. (çok ölçekli özellik haritaları)

FPN aşağıdan yukarıya bir yol ve yukarıdan aşağı bir yoldan oluşur.

NOT: Düşük seviyeli yapılardan oluşan görüntü katmanına daha yakın olan özellik haritaları, doğru nesne tespiti için etkili olmaz.

NOT: FPN, giriş olarak rastgele boyuttaki tek ölçekli görüntüyü alan ve tam evrişimli bir şekilde birden fazla düzeyde orantılı boyutlu özellik haritaları çıkaran bir özellik çıkarıcıdır. Omurga mimarisinden farklıdır. Boyun mimarisi olarak geçer genelde.

IoU Nedir?

Intersection over Union : Nesne algılamayla ilgili uygulamalarda kullanılır. Amaç; Doğru çerçeve ve tahmin sonucu oluşan çerçeve tamamen örtüşene kadar; Yani IoU=1 olana kadar tahmini geliştirmeye devam etmektir. 0 ve 1 arasında bir değere sahiptir.

$$IoU = \text{Kesişme Alanı} / \text{Birleşme Alanı}$$

DCN Nedir?

Temel amacı geleneksel CNN'lerdeki evrişim işlemindeki sert ve sabit örüntü eşleşmelerini geliştirmektir.

Geleneksel evrişim katmanları, görüntü üzerindeki özellikleri tek bir pencereden(kernel) işler ve bu pencerenin boyutu her katmanda aynıdır. Nesne tespiti işlemlerinde nesneler farklı boyutlarda ve şekillerde olabileceği ve özellikle kenarlarda yer aldığı sınırlarda bulunan özellikleri doğru bir şekilde tespit etmek önemlidir. DCN bu tür zorluklara çözüm olmak için tasarlanmıştır.

DCN, geleneksel evrişim katmanlarına göre şu temel avantajlara sahiptir:

Deformable Convolution: DCN, evrişim işlemi sırasında kernelin her bir noktasını esnek hale getirir. Bu, nesnelerin kenarlarını veya dönüşlerini daha iyi algılamak için özellik haritasını daha dinamik bir şekilde incelemesine olanak tanır.

Adaptive Sampling: DCN, pikselleri farklı ölçeklerde ve yüksekliklerde örneklemek için adaptif bir örnekleme mekanizması kullanır. Bu, nesnelerin daha iyi tespit edilmesini sağlar.

Uzaysal Duyarlılık: DCN, evrişim katmanlarının uzaysal duyarlılığını artırır ve böylece nesnelerin daha hassas konumlarını tespit etmeyi sağlar.

SGD Optimizasyonu Nedir?

Amacı bir modelin kayıp fonksiyonunu (loss function) minimize etmek için model parametrelerini güncellemektir.

Ana avantajı; Büyük veri seti ve büyük model parametrelerini eğitirken hesaplama maliyetini düşürmesidir.

Çalışma Mantığı:

1. Başlangıçta, modelin parametrelerini (ağırlıklarını) rastgele veya belirli bir başlangıç değeri ile başlatın.

2. Eğitim veri kümesini rastgele karıştırın veya rasgele örnekler alın. Bu, modelin her bir eğitim döneminde farklı örneklerle güncellenmesini sağlar.

3. Her bir eğitim örneği için aşağıdaki adımları izleyin:

a. Örnek üzerindeki tahmini sonuçları hesaplayın (ileri besleme - forward propagation).

b. Gerçek sonuçlarla tahminler arasındaki kaybı (loss) hesaplayın.

c. Kaybı minimize etmek için ağırlıkları güncellemek için gradyanı hesaplayın.

d. Gradyanı kullanarak ağırlıkları güncelleyin:

Yeni Ağırlık = Eski Ağırlık - (Öğrenme Hızı * Gradyan)

4. Belirli bir epoch (eğitim dönemi) boyunca bu işlemi veri kümesindeki tüm örnekler için tekrarlayın. Genellikle bir veri kümesinin tüm örnekleri bir defa geçtiğinde bir epoch tamamlanır.

5. Belirli bir sayıda epoch veya başka bir durum belirli bir kriteri karşılayana kadar bu işlemi tekrarlayın. Bu, modelin eğitim sürecini tamamlar.

NOT: Genellikle büyük veri kümeleri ve karmaşık modellerle çalışırken tercih edilir.

NOT: SGD'nin ana hiperparametreleri arasında; learning rate, mini-batch boyutu, momentum ve düzenleme terimleri gibi faktörler yer alır.